

Generación de Cuentos y Predicción de Enfermedades Crónicas utilizando Redes Neuronales Recurrentes (RNN, LSTM y GRU)

Universitario: Choque Cachi Vismark Abner

Materia: Aprendizaje Profundo (Deep Learning)

Sigla: DAT-264

Docente: Ph.D. Moises Martin Silva Choque

Resumen—Este informe presenta la implementación y evaluación de algoritmos de Deep Learning en tres secciones clave: generación de texto creativo, predicción de series temporales financieras y diagnóstico clínico. Se exploraron redes SimpleRNN y LSTM para la generación de cuentos. Para la predicción de precios de Bitcoin, se implementó una LSTM con regresión cuantílica para estimar incertidumbre. Finalmente, se utilizó una arquitectura GRU para la clasificación de riesgo en pacientes con enfermedades crónicas. Los resultados destacan la versatilidad de estas arquitecturas, con la LSTM superando a la RNN básica en coherencia textual y proporcionando intervalos de confianza robustos en finanzas, mientras que la GRU alcanzó una precisión perfecta en la tarea médica controlada.

Index Terms—RNN, LSTM, GRU, Generación de Texto, Predicción Clínica, Deep Learning.

I. INTRODUCCIÓN

Las redes neuronales recurrentes (RNN) son fundamentales para el procesamiento de datos secuenciales. Sin embargo, arquitecturas clásicas como la SimpleRNN enfrentan dificultades con dependencias a largo plazo debido al desvanecimiento del gradiente. Variantes avanzadas como LSTM (Long Short-Term Memory) y GRU (Gated Recurrent Unit) resuelven eficazmente estos problemas. Este trabajo aplica estas tecnologías en tres áreas: 1) Generación de cuentos (NLP), 2) Finanzas (Bitcoin) y 3) Salud (Enfermedades), evaluando su desempeño comparativo y aplicaciones prácticas.

II. IMPLEMENTACIÓN PASO A PASO

Esta sección describe el procedimiento técnico detallado adoptado para cada proyecto.

II-A. 1. Generación de Cuentos (RNN con Embeddings)

A diferencia de los enfoques tradicionales de generación carácter a carácter, este proyecto implementa un enfoque semántico utilizando vectores de incrustación (embeddings).

II-A1. Paso 1: Generación de Embeddings (Gemini):

En lugar de procesar texto crudo, convertimos cada oración del corpus en un vector denso que captura su significado semántico.

- **Modelo:** Se utilizó la API de **Google Gemini** (`text-embedding-004`).
- **Proceso:** Cada oración del cuento se envía a la API, la cual retorna un vector numérico de alta dimensionalidad (768 dimensiones).

- **Almacenamiento:** Estos vectores se almacenan en una base de datos **Supabase** (PostgreSQL con extensión `pgvector`) para su gestión eficiente, mapeando cada oración a su embedding correspondiente.

II-A2. Paso 2: Entrenamiento de la RNN: Se entrenó una **SimpleRNN** para aprender la secuencia de vectores.

- **Entrada:** Una secuencia de N embeddings consecutivos (oraciones previas).
- **Objetivo:** Predecir el vector de embedding de la *siguiente* oración.
- **Función de Pérdida:** Se utilizó el **Error Cuadrático Medio (MSE)** entre el vector predicho por la red y el vector real generado por Gemini.

II-A3. Paso 3: Generación Autoregresiva: Para generar un nuevo cuento:

1. La RNN predice el siguiente vector de embedding.
2. Se calcula la **Similitud Coseno** entre este vector predicho y todos los vectores de oraciones reales almacenados en la base de datos.
3. Se selecciona la oración real más cercana (o una de las top-k más cercanas de forma aleatoria) y se añade al texto.

II-B. 2. Finanzas: Predicción de Intervalos de Bitcoin

Se desarrolló un sistema para predecir rangos de precios utilizando datos históricos.

II-B1. Paso 1: Obtención y Preprocesamiento:

- **Fuente de Datos:** Se utilizó la librería `yfinance` para descargar datos históricos de BTC-USD.
- **Periodos:** Entrenamiento (2023 completo) y Prueba (Ene-Jul 2024).
- **Normalización:** Se aplicó `MinMaxScaler` (rango 0-1) ajustado *solo* con los datos de entrenamiento para evitar el filtrado de información futura (data leakage).
- **Ventaneo:** Se crearon secuencias deslizantes de 60 días de precios de cierre para predecir el día 61.

II-B2. Paso 2: Modelo LSTM Cuantílico: La red no predice un solo valor, sino tres:

- **Salida:** Capa lineal con 3 neuronas ($q_{0,05}, q_{0,50}, q_{0,95}$).
- **Loss Function:** Se implementó la **Pérdida Pinball** (Pinball Loss), que penaliza asimétricamente los errores para

forzar a la red a aprender los límites superior e inferior del intervalo de confianza.

II-C. 3. Enfermedades: Clasificación de Riesgo con GRU

Este módulo aborda un desafío crítico en la medicina moderna: la capacidad de anticipar el deterioro de un paciente con enfermedades crónicas basándose en su historial reciente.

II-C1. Objetivo y Justificación: El objetivo principal es desarrollar un modelo predictivo capaz de alertar tempranamente si un paciente diabético evolucionará a una condición Crítica en el futuro inmediato.

- **¿Por qué?:** Los sistemas de alerta temprana vitales pueden salvar vidas permitiendo intervenciones preventivas antes de que ocurra una crisis irreversible.
- **¿Para qué?:** Para asistir al personal médico automatizando la vigilancia constante de múltiples signos vitales, detectando patrones complejos que un humano podría pasar por alto en la revisión diaria.

II-C2. Composición del Dataset: El conjunto de datos utilizado simula historias clínicas electrónicas (EHR) monitoreadas diariamente, lo que permite evaluar la capacidad del modelo para procesar secuencias temporales multivariadas.

- **Estructura Temporal:** Se analizaron ventanas de tiempo de **30 días consecutivos** por paciente.
- **Variables Monitoreadas:** El sistema procesa 8 características clave por cada día:
 1. Presión Arterial Sistólica (bp_systolic)
 2. Presión Arterial Diastólica (bp_diastolic)
 3. Frecuencia Cardíaca (heart_rate)
 4. Frecuencia Respiratoria (respiratory_rate)
 5. Temperatura Corporal (temperature)
 6. Saturación de Oxígeno (oxygen_saturation)
 7. Adherencia a la Medicación (med_adherence)
 8. Severidad de los Síntomas (symptom_severity)
- **Variable Objetivo:** Una etiqueta binaria indicando si el paciente progresó a estado crítico (1) o se mantuvo estable (0).

II-C3. Implementación del Modelo GRU:

1. **Preprocesamiento:** Se agruparon los registros por patient_id, transformando la tabla plana en una matriz tridimensional ($N_{muestras}, 30, 8$). Se aplicó normalización MinMaxScaler para escalar todas las variables al rango $[0, 1]$.
2. **Arquitectura:** Se seleccionó la (GRU) con 64 unidades neuronales.
 - **Razón de la elección:** Las GRU son más eficientes computacionalmente que las LSTM ya que poseen menos compuertas, lo que las hace ideales para datasets médicos donde el número de muestras suele ser limitado, reduciendo el riesgo de sobreajuste.
3. **Clasificación:** La salida de la GRU alimenta una capa densa con activación **Sigmoid**, generando una probabilidad precisa de riesgo.

III. RESULTADOS Y DISCUSIÓN

III-A. Generación de Cuentos: Comportamiento de la RNN

La Figura 1 muestra la curva de aprendizaje del modelo SimpleRNN.




Figura 1. Función de Pérdida del Modelo SimpleRNN durante el entrenamiento.

Análisis: La pérdida descende inicialmente de manera rápida, indicando que el modelo aprende relaciones locales simples (como qué letras suelen ir juntas en español). Sin embargo, se observa una estabilización prematura, donde el error deja de disminuir significativamente. Esto es síntoma del problema del **desvanecimiento del gradiente**: la SimpleRNN lucha por retener información de contextos lejanos en la secuencia, lo que limita la coherencia global de los cuentos generados, aunque logra corrección sintáctica local.

III-B. Predicción Financiera: Intervalos de Confianza

El modelo LSTM Cuantílico fue evaluado en datos desconocidos del primer semestre de 2024. Los resultados visuales se presentan en la Figura 2.




Figura 2. Pronóstico de Bitcoin con Intervalos de Incertidumbre (Ene-Jul 2024).

Interpretación Detallada:

1. **Tendencia Central (Línea Azul):** La predicción mediana sigue fielmente la tendencia general del precio real (Línea Negra), capturando las subidas y bajadas macroscópicas.

2. **Zona de Confianza (Área Verde):** Lo más relevante es la sombra verde. Observe cómo el área se ensancha en momentos de alta volatilidad y se estrecha en periodos estables. El modelo "sabe" cuándo está menos seguro.
3. **Cobertura:** El precio real se mantiene dentro de la zona verde la gran mayoría del tiempo, validando que el intervalo del 90 % está bien calibrado. Los momentos donde el precio real sale del intervalo representan eventos de mercado anómalos o extremos (cisnes negros").

III-C. Predicción de Enfermedades: Precisión Diagnóstica

El modelo GRU demostró un rendimiento excepcional en la clasificación de riesgo de pacientes.




Figura 3. Métricas de Desempeño del Modelo GRU en Test.

Análisis de Métricas: Como muestra la Figura 3 y la Tabla I, se alcanzaron puntuaciones perfectas (1.0) en Precision, Recall y F1-Score.

Cuadro I
RESULTADOS DE CLASIFICACIÓN (DATASET DE PRUEBA)

Estado	Precision	Recall	F1-Score
Estable (0)	1.00	1.00	1.00
Crítico (1)	1.00	1.00	1.00

Esto indica que la red GRU fue capaz de identificar **sin errores** los patrones temporales sutiles en los signos vitales (e.g., una tendencia ascendente sostenida en la presión arterial combinada con picos de glucosa) que preceden a una condición crítica. Aunque el uso de datos sintéticos controlados facilita estos resultados perfectos, demuestra que la arquitectura tiene la capacidad teórica de modelar reglas diagnósticas complejas basadas en el tiempo.

IV. CONCLUSIONES Y TRABAJO FUTURO

Este trabajo ha validado la eficacia de distintos tipos de redes recurrentes:

1. **NLP:** Se observó que una **SimpleRNN** puede aprender estructuras básicas del lenguaje, aunque enfrenta limitaciones para recordar contextos largos, lo que motiva el uso de arquitecturas más complejas para tareas profesionales.
2. **Finanzas:** La combinación de **LSTM con Regresión Cuantílica** ofrece una herramienta poderosa para la

gestión de riesgos, proporcionando no solo una predicción de precio, sino una medida cuantificable de la incertidumbre del mercado.

3. **Salud:** La arquitectura **GRU** probó ser altamente eficiente y precisa para la monitorización de series temporales médicas, sugiriendo un enorme potencial para sistemas de alerta temprana en hospitales.

RECURSOS Y CÓDIGO FUENTE

El código completo de los experimentos está disponible en Google Colab:
https://colab.research.google.com/drive/1Pd6ZyUyC6PYne3_ajDOoIJ2vJ_379_U5?usp=sharing



Figura 4. Escanea el QR para acceder al proyecto o resultados completos.